Machine Learning

Introducción

Dr. Mauricio Toledo-Acosta

Diplomado Ciencia de Datos con Python 2025

Table of Contents

¿Qué es la Inteligencia Artificial?
¿Qué es el Aprendizaje Automático?

¿Qué es la Inteligencia Artificial?

Definición práctica

La Inteligencia Artificial (IA) son sistemas que imitan capacidades humanas como:

- Aprender de ejemplos (como recomendar videos)
- Interpretar datos (reconocer rostros en fotos)
- Tomar decisiones (asistentes virtuales)

Tipos de IA

- Que *piensan* como humanos
  asistentes predictivos, chatbots
- Que *actúan* como humanos
  robots

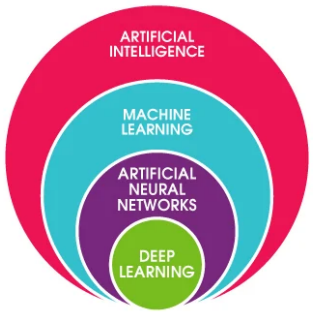

Algunas áreas de la IA

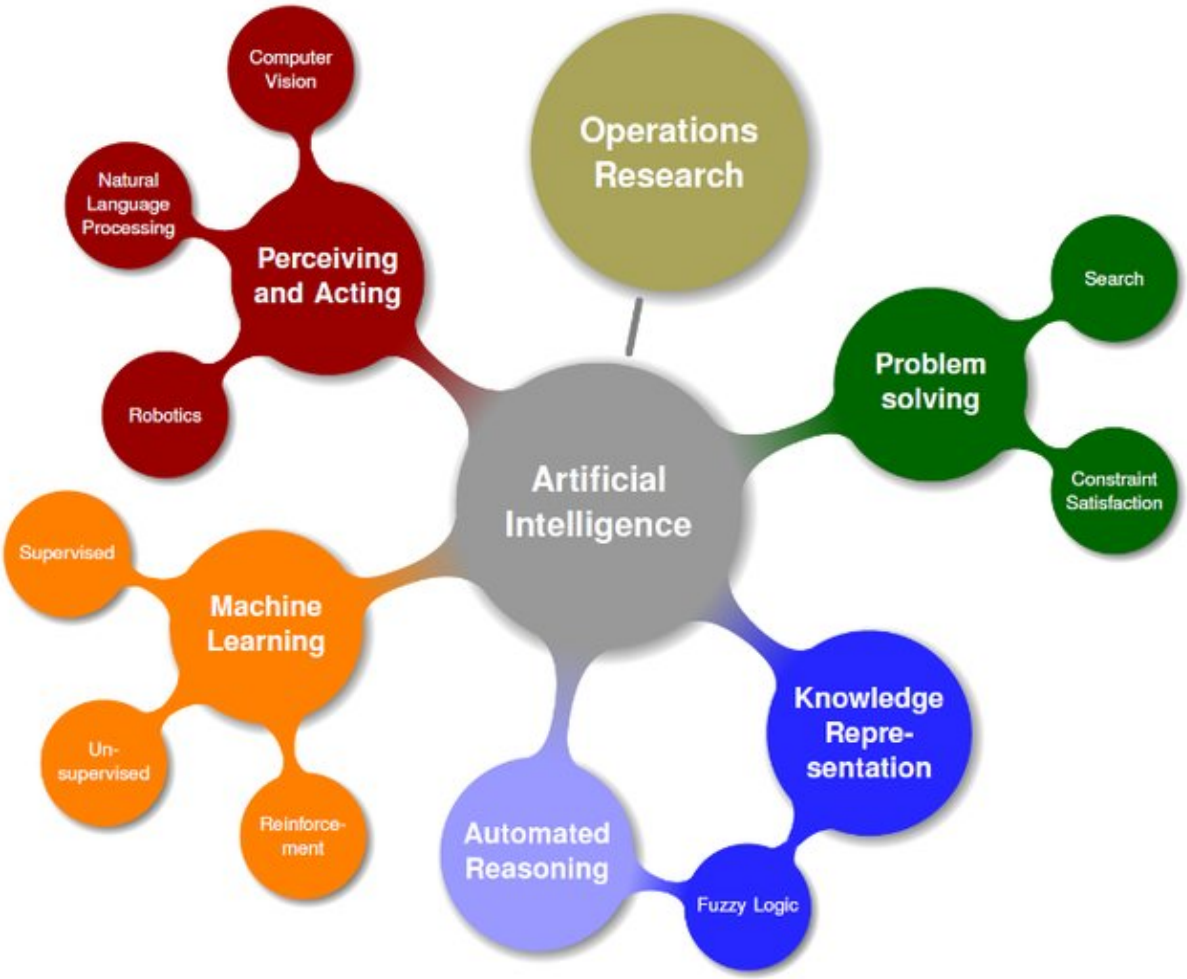

doi:10.13140/RG.2.2.23097.80485

Evolución de la IA

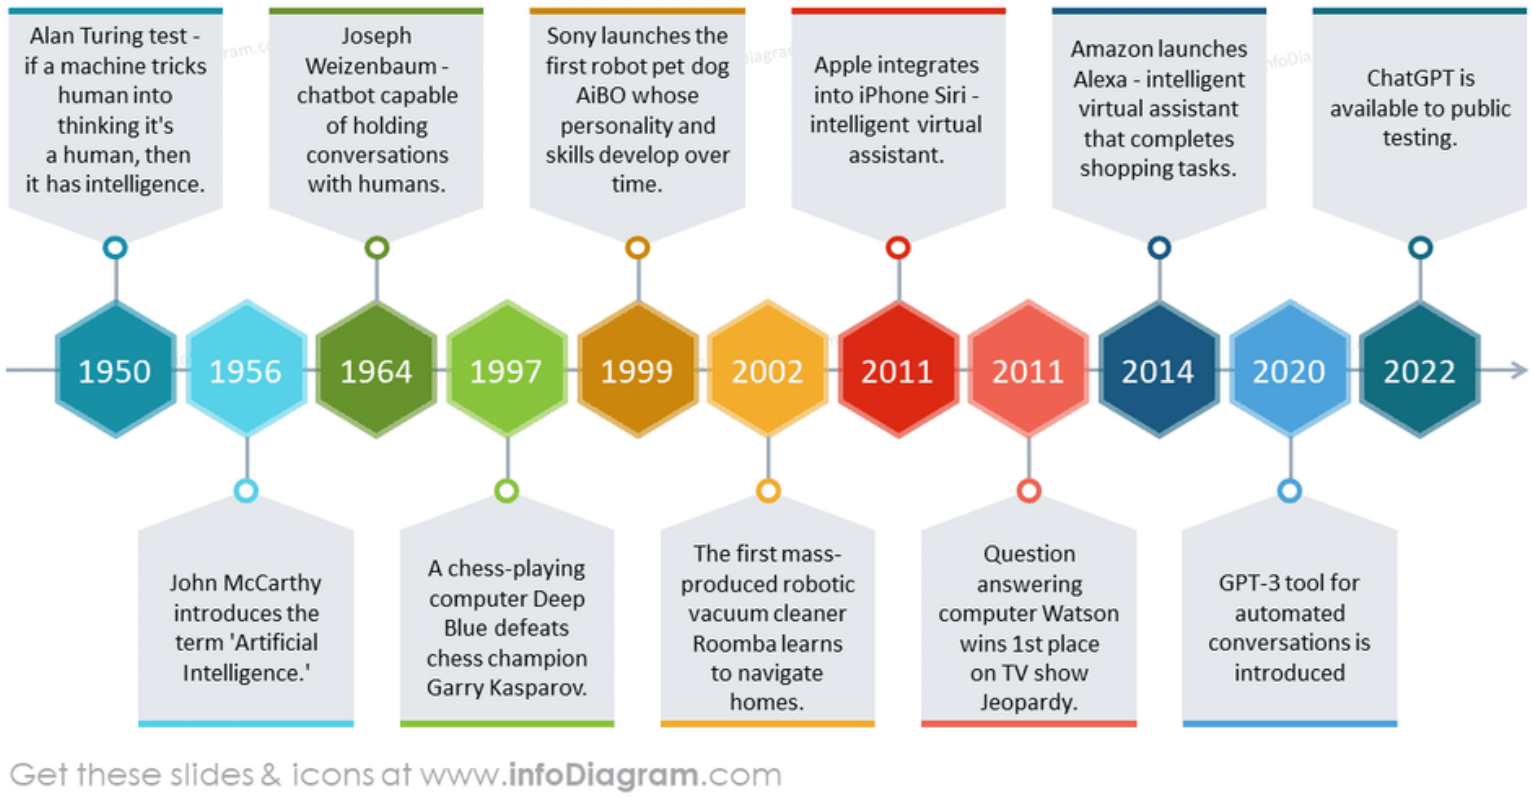

https://qbi.uq.edu.au/brain/intelligent-machines/history-artificial-intelligence

¿Qué es el Machine Learning?

Machine Learning (Aprendizaje Automático)

El Machine Learning es una rama de la inteligencia artificial, cuyo objetivo es desarrollar técnicas que permitan que las computadoras aprendan con el objetivo de resolver ciertas tareas.

Temario

Aprendizaje Automático

- Preprocesamiento
  - Limpieza de datos
  - Transformación
  - Evaluación
- Clasificación/Regresión
  - Regresión lineal y logística
  - Árboles de decisión
  - SVM
- Agrupamiento
  - K-Means
  - PCA/t-SNE

Deep Learning

- Redes neuronales
  - Arquitectura MLP
  - Funciones de activación
- Redes convolucionales
  - Arquitectura CNN
  - Aplicaciones
- Modelos avanzados
  - Autoencoders
  - Redes secuenciales

Paradigmas computacionales

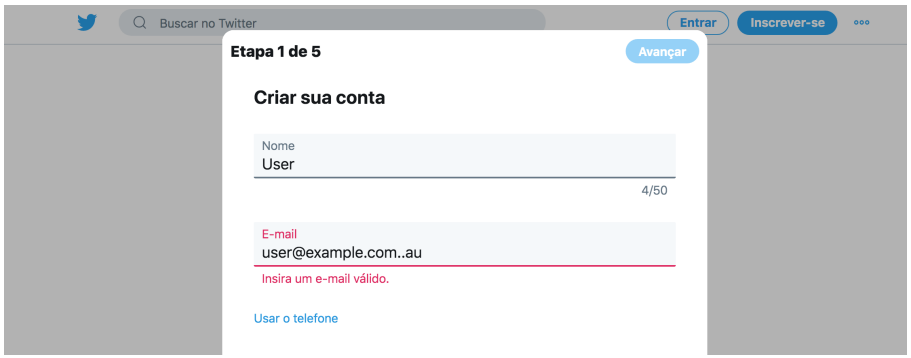

Programación Tradicional

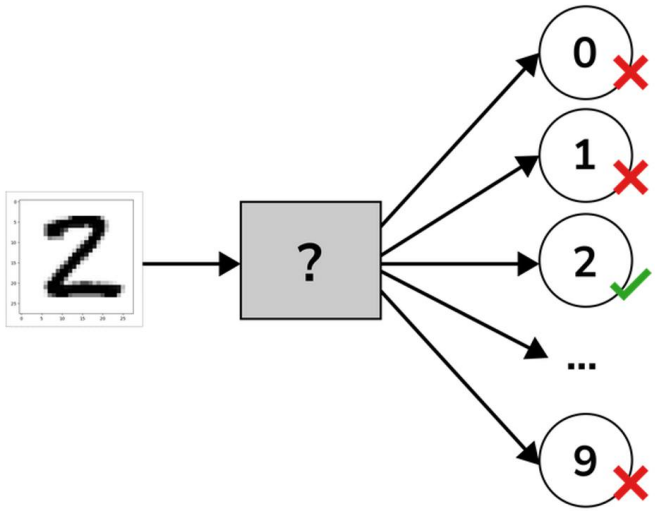

Machine Learning

Dos paradigmas complementarios para resolver problemas computacionales:

Enseñar a un niño vs Programar un robot.

Machine Learning vs Algoritmos tradicionales

Un algoritmo tradicional toma una entrada y una lógica en forma de código y genera una salida para resolver un problema.

Machine Learning vs Algoritmos tradicionales

Un algoritmo tradicional toma una entrada y una lógica en forma de código y genera una salida para resolver un problema.

Por el contrario, un algoritmo de aprendizaje automático toma una entrada y una salida y aprende una lógica que puede utilizarse para trabajar con nuevas entradas y obtener una salida. Esta lógica se obtiene a partir de los patrones presentes en los datos.

Machine Learning vs Algoritmos tradicionales

Un algoritmo tradicional toma una entrada y una lógica en forma de código y genera una salida para resolver un problema.

Por el contrario, un algoritmo de aprendizaje automático toma una entrada y una salida y aprende una lógica que puede utilizarse para trabajar con nuevas entradas y obtener una salida. Esta lógica se obtiene a partir de los patrones presentes en los datos.

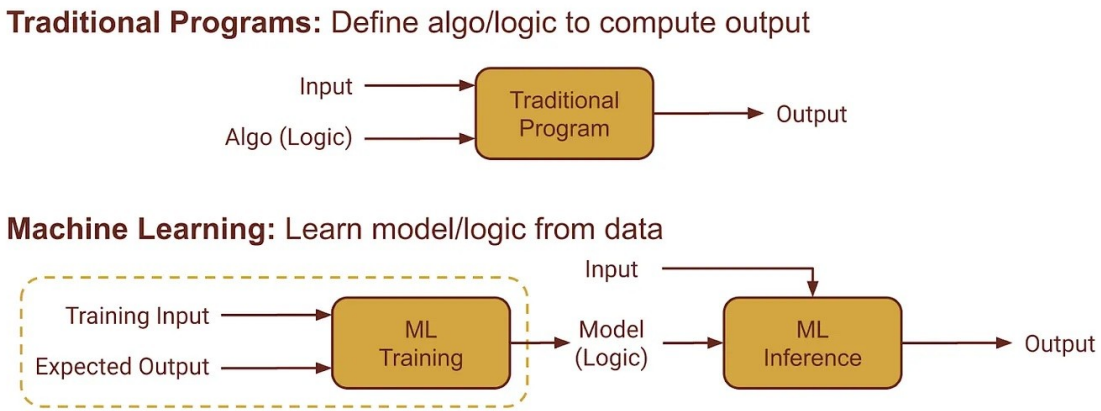

https://www.linkedin.com/pulse/machine-learning-vs-traditional-software-development-ml4devs-gupta

Fases de un programa de Machine Learning

Los programas de aprendizaje automático tienen dos fases distintas:

1. Entrenamiento: Las entradas y la salida esperada se utilizan para entrenar y probar varios modelos. Se selecciona el modelo más adecuado. *Entrenar* quiere decir determinar los parámetros adecuados del modelo para producir la salida esperada, a partir de las entradas.

2. Inferencia o predicción: El modelo se aplica a nuevos datos de entrada para predecir nuevas salidas, las cuales pueden compararse con las salidas reales.

¿Por qué necesitamos el Machine Learning?

En el enfoque clásico, antes del ML, se usaban algoritmos que procesaban los datos con base en reglas lógicas (`if, else, ...`).

Ejemplo: La detección de correo spam.

¿Por qué necesitamos el Machine Learning?

En el enfoque clásico, antes del ML, se usaban algoritmos que procesaban los datos con base en reglas lógicas (`if, else, ...`).

- La lógica para tomar las decisiones es específica de acuerdo al dominio y a la tarea. Pequeños cambios en la tarea requieren rediseñar el sistema.
- El diseño de las reglas requiere un entendimiento profundo del dominio por parte de un experto. Estas reglas pueden ser muy complicadas.

Ejemplo: La detección de correo spam.

¿Qué tareas puede resolver el Machine Learning?

Algunas de las tareas que pueden resolver los métodos de Machine Learning son

1. Regresión.
2. Clasificación.
3. Clustering (segmentación).
4. Traducción automática.
5. Detección de anomalías.
6. Generación (texto, imágenes).

Los tres paradigmas del Machine Learning

1. Aprendizaje supervisado (Supervised Learning). El modelo aprende de ejemplos etiquetados para hacer predicciones de nuevos datos.
2. Aprendizaje no supervisado (Unsupervised Learning). El modelo encuentra patrones o estructuras intrínsecas en los datos sin etiquetar.
3. Aprendizaje por refuerzo (Reinforcement Learning). El modelo aprende las acciones a tomar en un entorno para maximizar una noción de recompensa acumulativa.

Los tres paradigmas del Machine Learning

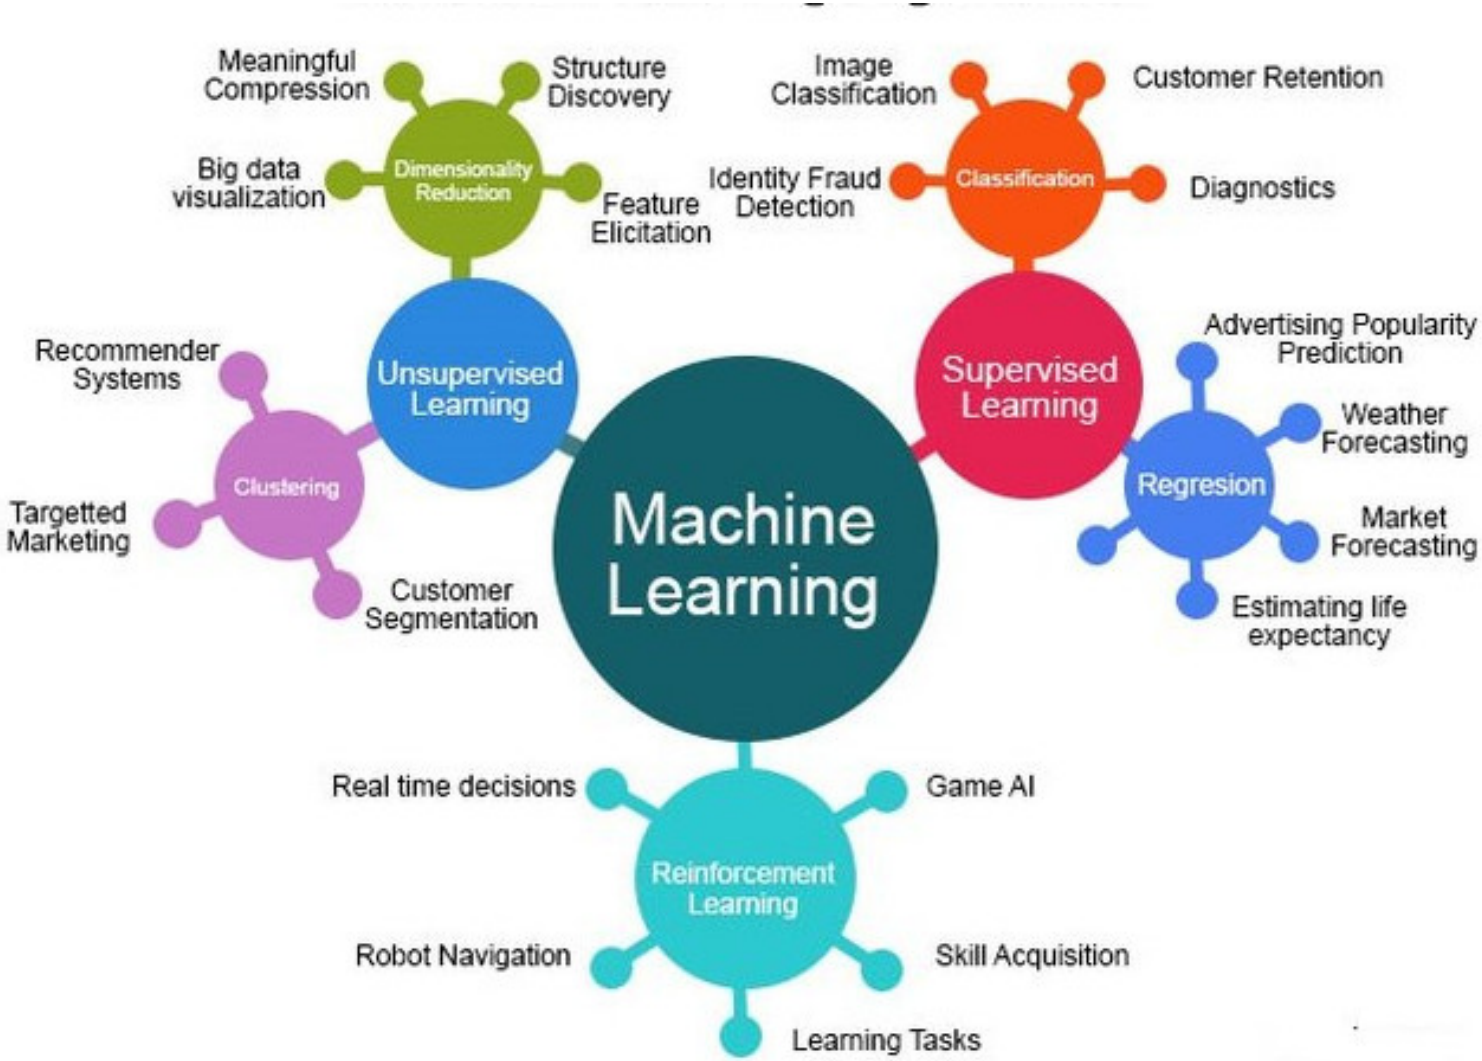

Machine Learning en Acción

- **Regresión:** Predecir precios de casas, predecir el consumo de energía eléctrica, predecir el precio de acciones.
- **Clasificación:** Diagnóstico médico, Identificación de rostros en fotos, identificación de spam, identificación de contenido ofensivo.
- **Clustering:** Segmentación de clientes, identificación de tópicos en documentos.

Aprendizaje Supervisado

1. Regresión.
2. Clasificación.

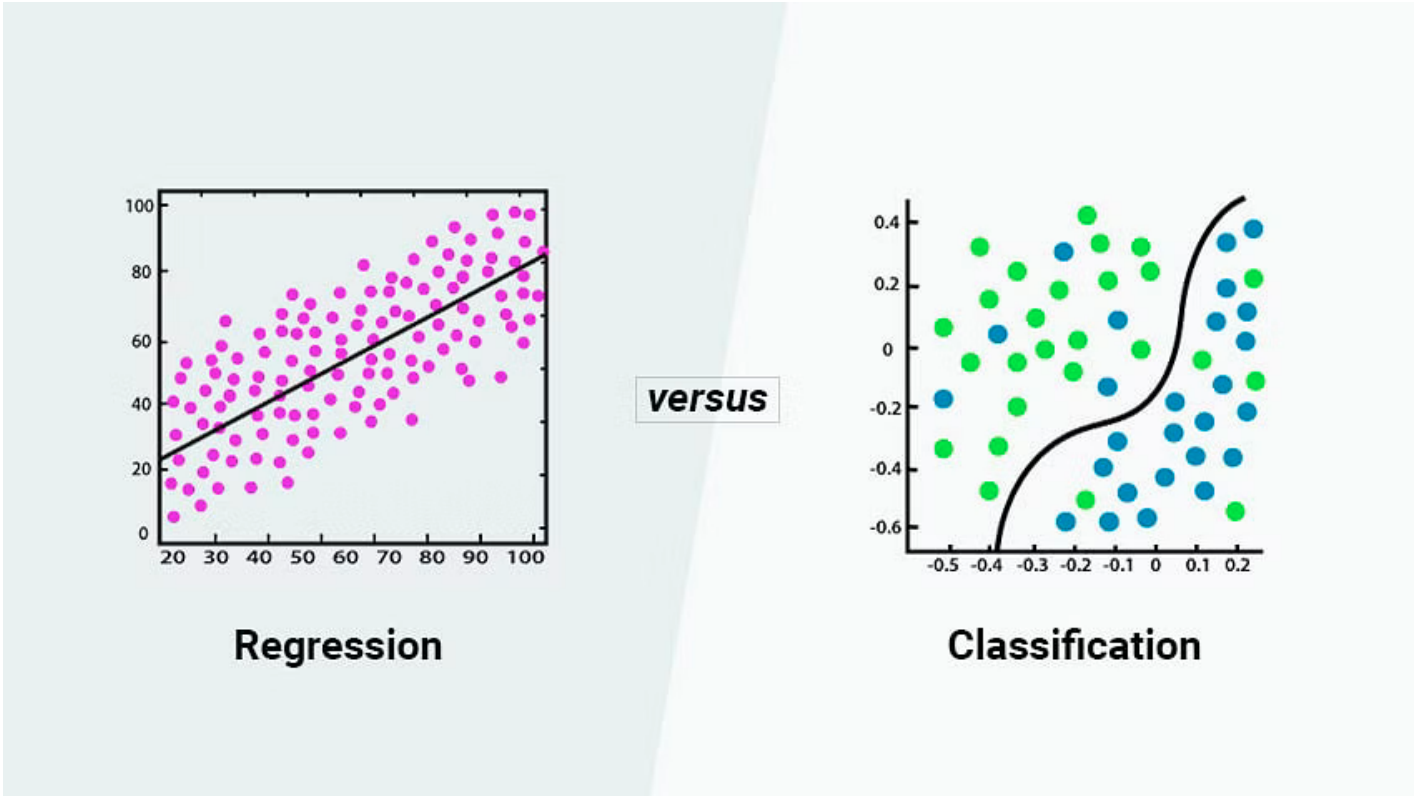

Aprendizaje No Supervisado

Clustering

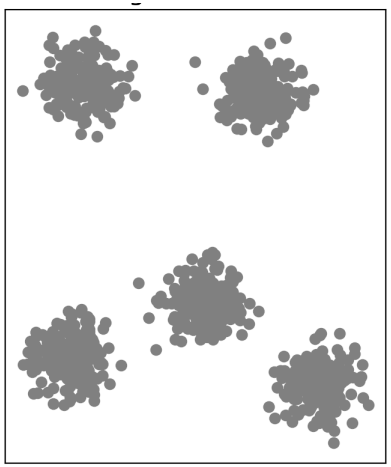

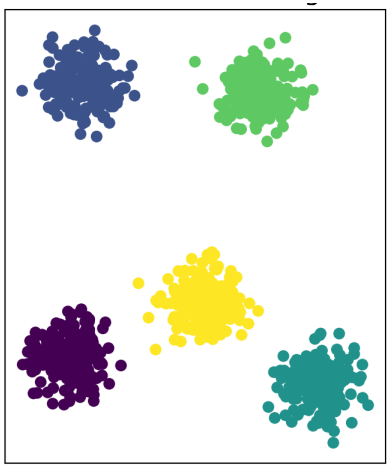

Reducción de dimensionalidad

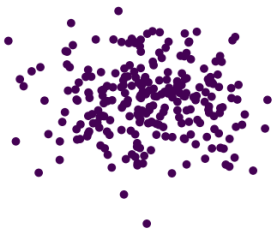

Aprendizaje por Refuerzo

1. Navegación en vehículos autónomos.
2. Texto predictivo.
3. Sistemas de recomendación.
4. Videojuegos.
5. Conservación y eficiencia energética.
6. Mejoramiento de los LLMs.

Timeline de los algoritmos de Machine Learning

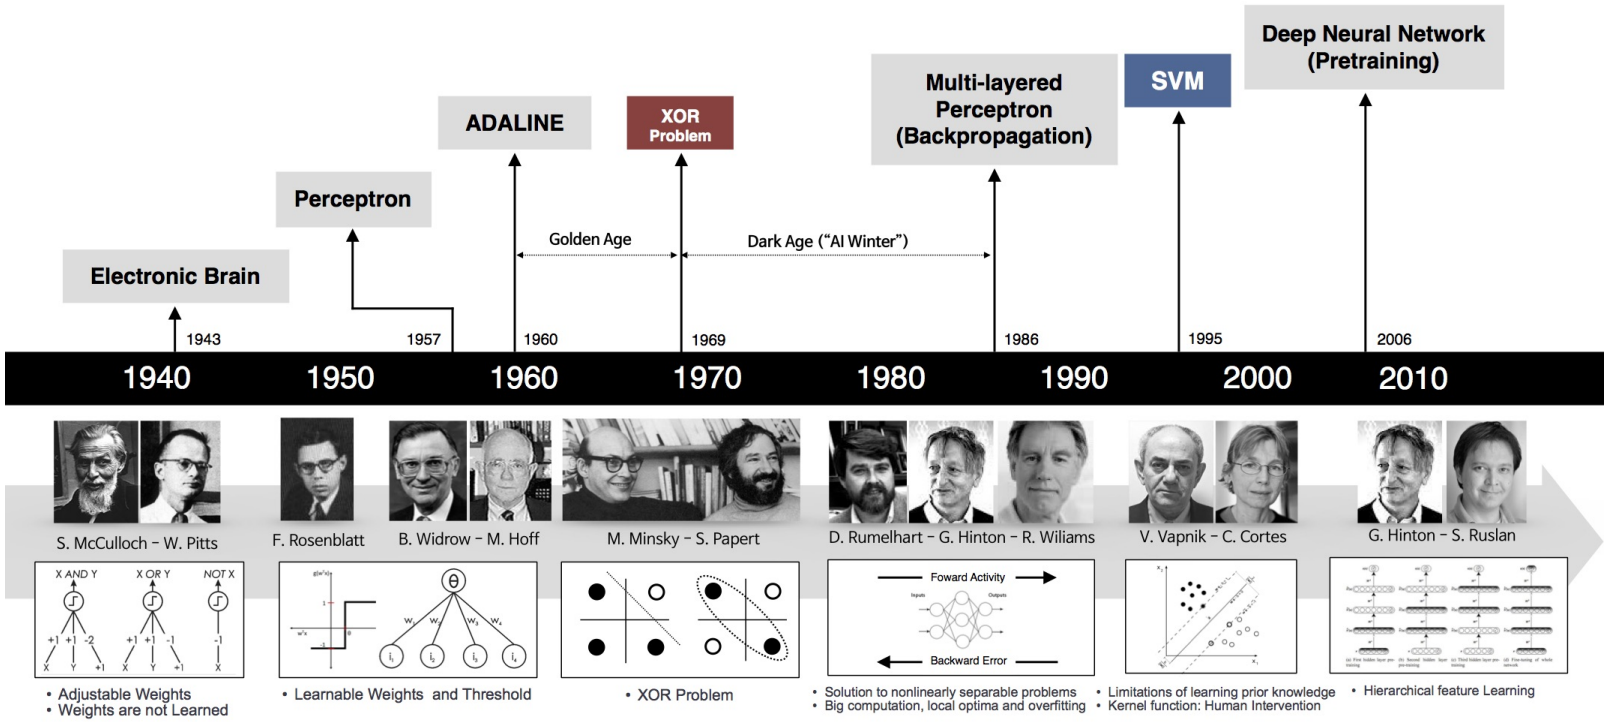

http://beamlab.org/deeplearning/2017/

Referencias

- Müller, A. C., & Guido, S., 2016. *Introduction to Machine Learning with Python: a Guide for Data Scientists*. O'Reilly Media, Inc..
- Flach, P. A., 2012. *Machine Learning : the Art and Science of Algorithms That Make Sense of Data*. Cambridge University Press.

Table of Contents

Componentes del Machine Learning

Datos

Variables (features)

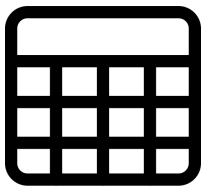

Algoritmos

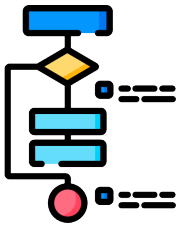

Métricas

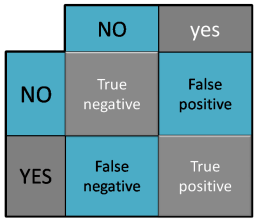

Ejemplo: Desde datos de correos hasta clasificar spam.

Workflow del Machine Learning

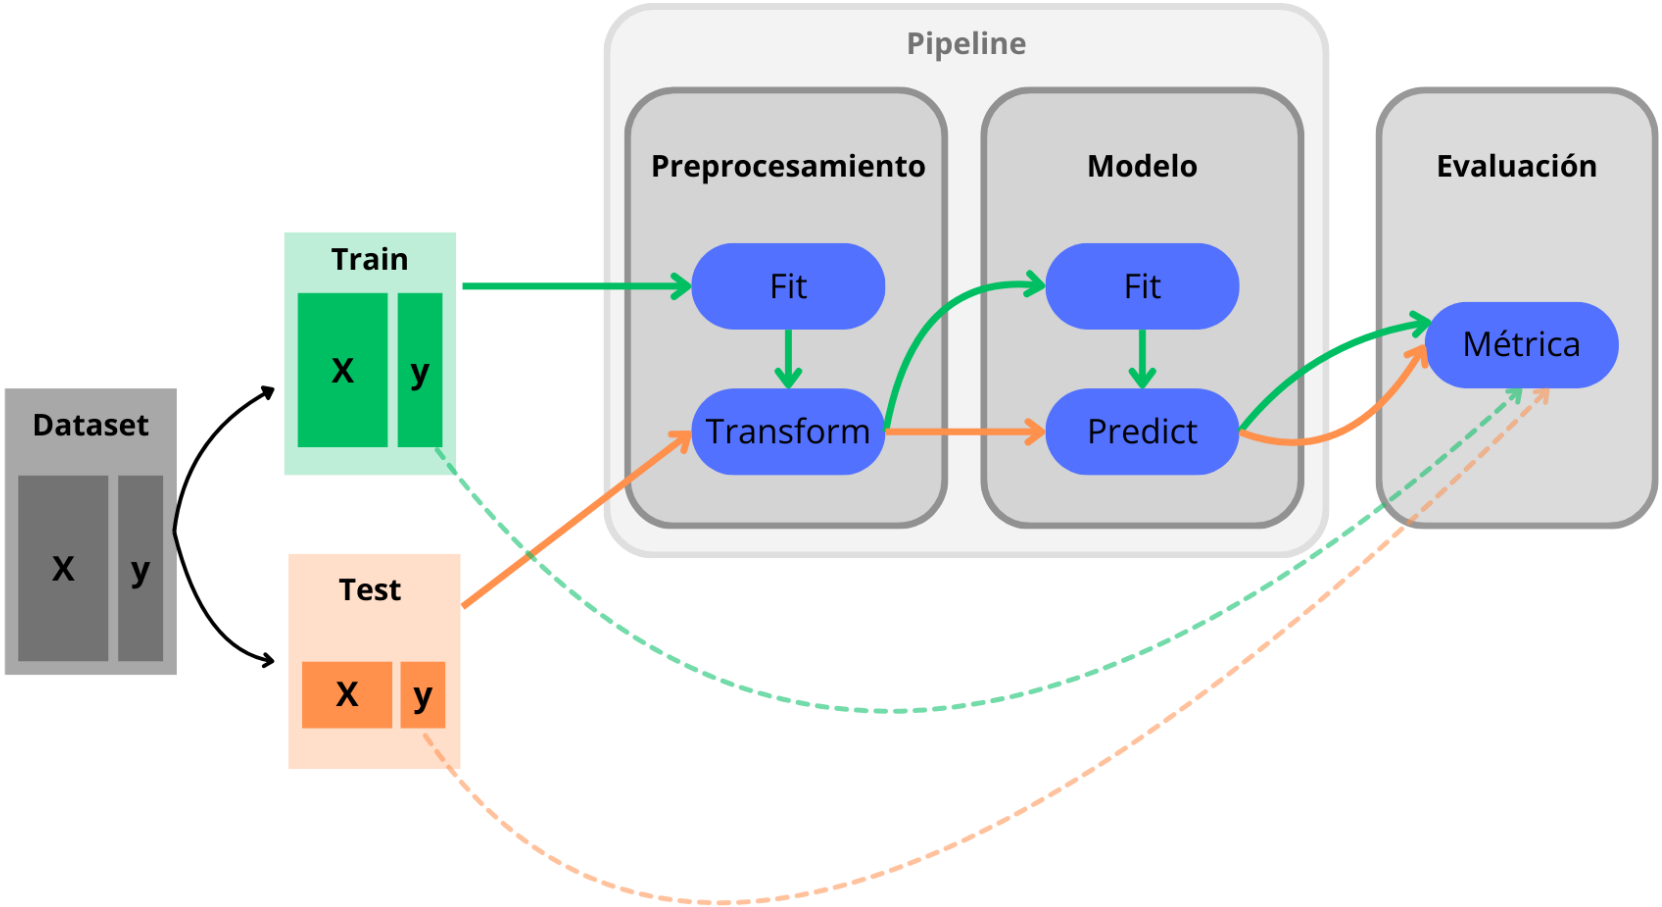

Datos

Los datos pueden tener formas diferentes:

- Tablas estructuradas
- Imágenes
- Texto
- Archivos de audio
- Archivos de video
- Series de tiempo
- Grafos

A un conjunto de datos, se le llama dataset (no es lo mismo que *base de datos*). Fuentes de datasets:

- Kaggle
- Scikit-Learn.
- HuggingFace

Algunos datasets famosos

- MNIST
- Iris Flowers Dataset.
- Boston House Price Dataset.
- Wine Quality Dataset.
- Pima Indians Diabetes Dataset.
- 20newsgroups.
- Titanic

Los **datos** son muy importantes de la ciencia de **datos**.

Features

Los datasets **son** tablas donde cada fila representa una entidad y cada columna una característica de esa entidad. Es decir, cada entidad esta representada por un conjunto de variables (features, características).

Hay varios tipos de variables:

- Numéricas
  - Continuas: temperatura, longitud.
  - Discretas: número de habitaciones, habitantes.
- Categóricas
  - Ordinales: escalas numéricas (grado de satisfacción, nivel educativo).
  - Nominales: representan clases (género, modelo).

  Las ordinales mantienen un orden lógico, las nominales son categorías sin jerarquía.

Ejemplo

Preprocesamiento

En cualquier proceso de Machine Learning, el preprocesamiento es el paso en el que los datos se limpian, transforman y/o codifican para llevarlos a un estado tal que ahora la máquina pueda analizarlos de *mejor forma*.

Preprocesamiento

En cualquier proceso de Machine Learning, el preprocesamiento es el paso en el que los datos se limpian, transforman y/o codifican para llevarlos a un estado tal que ahora la máquina pueda analizarlos de *mejor forma*.

Estos son algunos de los tipos de problemas básicos así como las técnicas de preprocesamiento a la que pertenecen:

- ¿Cómo limpio los datos? Limpieza de datos.
- ¿Cómo unifico y escalo los datos? Normalización de datos.
- ¿Cómo proporciono datos precisos? Transformación de datos.
- ¿Cómo manejo los datos faltantes? Imputación de datos perdidos.
- ¿Cómo incorporo y ajusto datos? Integración de datos.
- ¿Cómo detecto y manejo el ruido? Análisis del ruido.

Escalamiento MinMax

Definición

Escala los datos a un rango específico (por defecto [0, 1]).

$$x_{\text{scaled}} = \frac{x - \min(X)}{\max(X) - \min(X)}$$

Valores originales	Valores escalados
2	0
5	0.375
10	1

MinMaxScaler en scikit-learn

Escalamiento MinMax

Datos originales

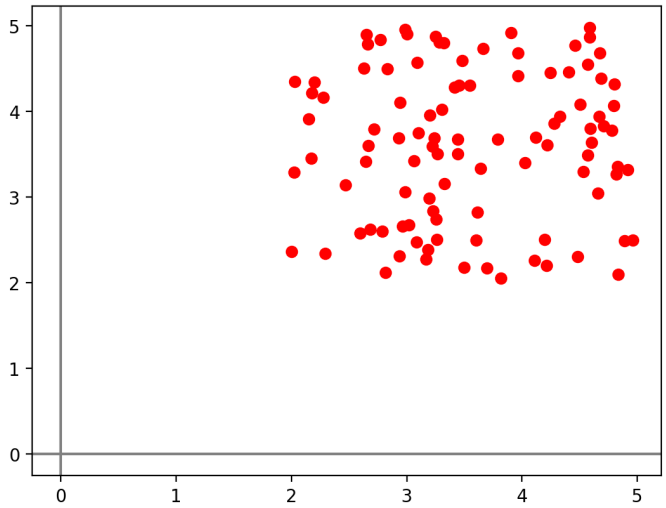

Preprocesamiento

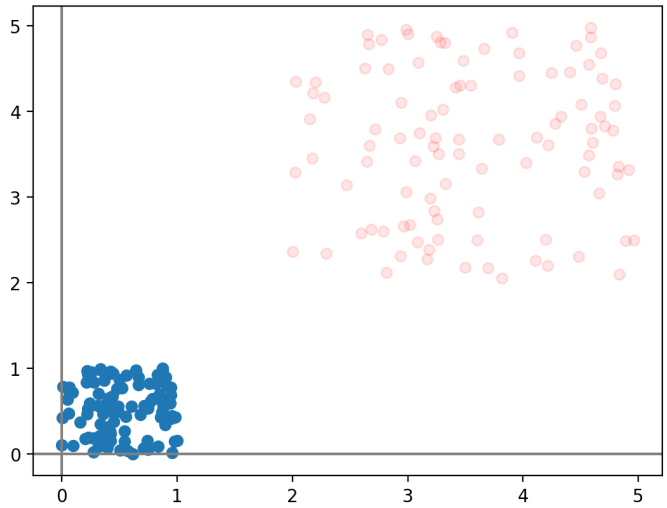

Escalamiento z-score

Definición

Estandariza los datos restando la media (μ) y dividiendo por la desviación estándar (σ).

$$x_{\text{scaled}} = \frac{x - \mu}{\sigma}$$

$\mu = 5.67$, $\sigma = 3.06$:

Valores originales	**Valores escalados**
2	-1.20
5	-0.22
10	1.41

StandardScaler en scikit-learn

Escalamiento z-score

Datos originales

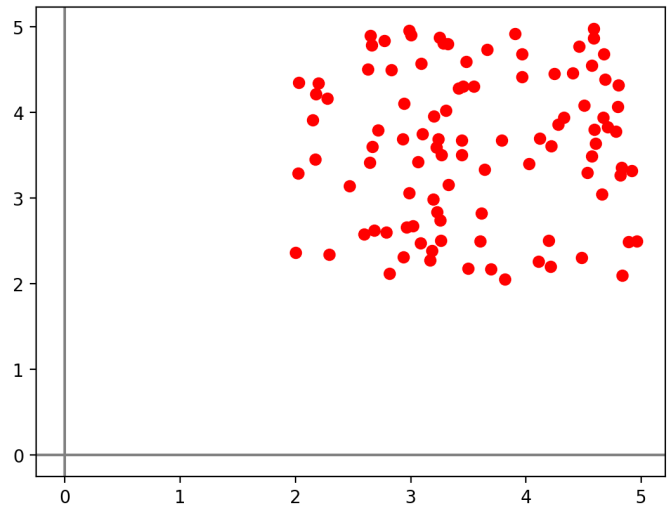

Preprocesamiento

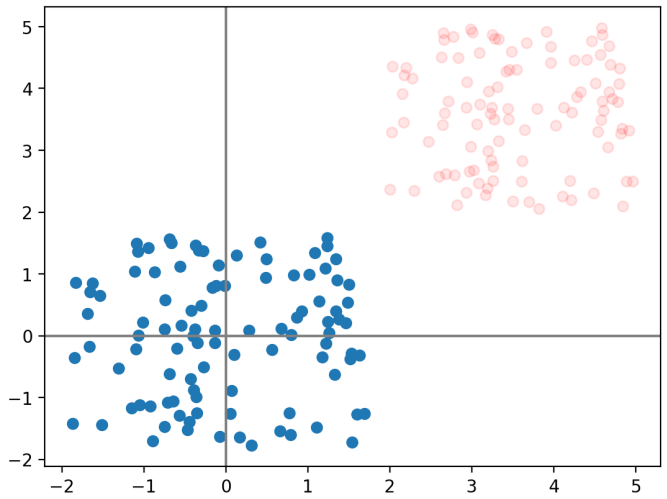

`https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html`

Escalamiento L_1 o L_2

Definición

Transforma cada **fila** o **columna** para que la suma de sus valores absolutos sea 1.

$$x_{\text{norm}} = \frac{x_i}{\left(\sum_{j=1}^{n} |x_j|^p\right)^{\frac{1}{p}}}$$

con $p = 1$ o $p = 2$.

Original	Normalizado (filas)	Normalizado (columnas)
1, 2, 3	0.17, 0.33, 0.50	0.25, 0.33, 0.43
4, 0, 1	0.80, 0.00, 0.20	1.00, 0.00, 0.14

Normalización en scikit-learn

Escalamiento L_1 o L_2

Escalamiento L_1

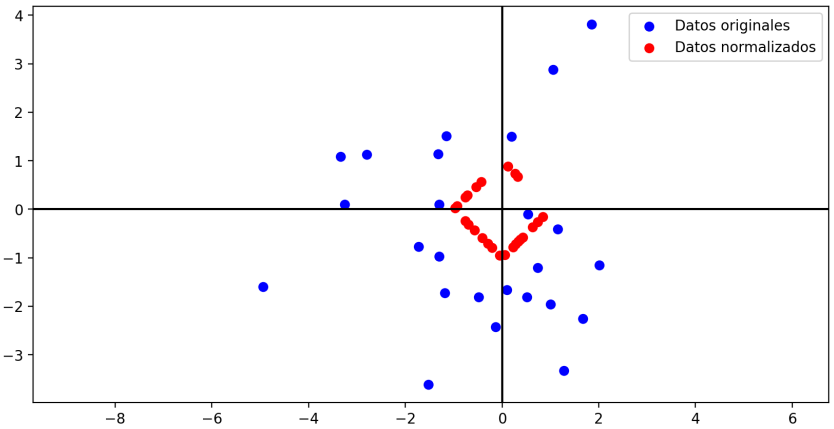

Escalamiento L_2

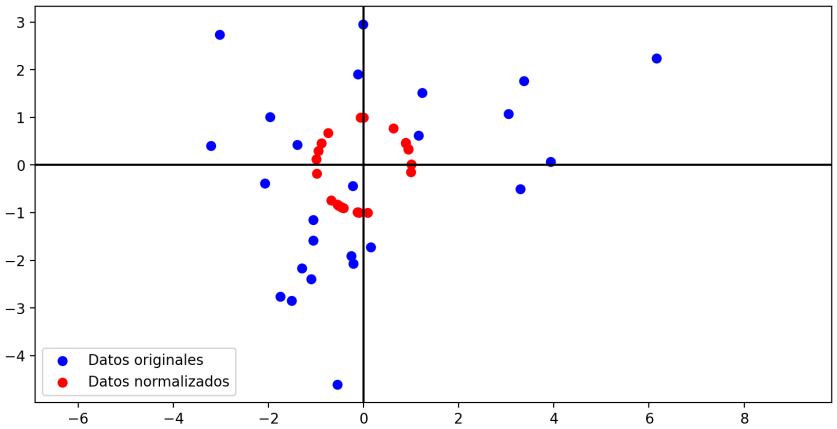

Este escalamiento es útil cuando se trata de representaciones vectoriales (*embeddings*) de texto, imágenes, etc.

Imputación

Definición

Rellena valores faltantes usando estrategias la media, mediana o moda de la fila (o columna).

$$\text{Media} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

También se puede rellenar con valores predefinidos.

Original	**Imputado (media)**
1	1
NaN	3.33
4	3
5	5

Selección de Features: SelectKBest

Definición

Selecciona las k features con mayor puntuación según test estadístico. Selecciona las k características más relevantes según qué tan bien separan los grupos de tus datos.

Imagina que quieres distinguir entre perros y gatos

- Característica 1: Número de bigotes (buen discriminador)
- Característica 2: Peso
- Característica 3: Color del collar (mal discriminador)

Característica	**Puntaje**
Bigotes	22.1
Peso	15.2
Color collar	3.8

SelectKBest en scikit-learn

Selección de Features: SelectKBest

Datos originales

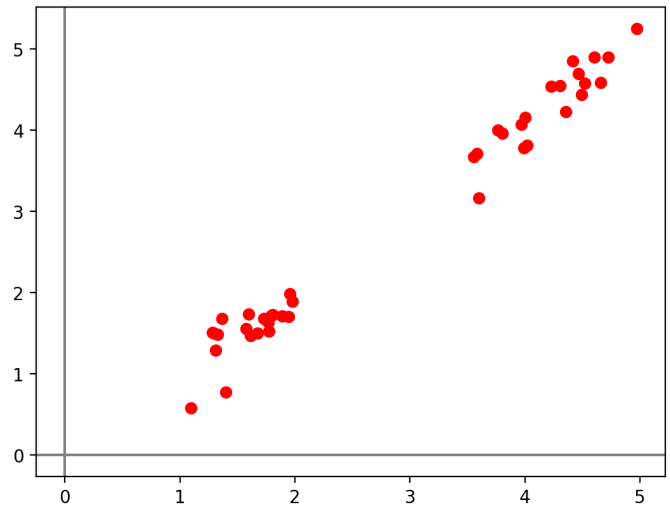

Preprocesamiento

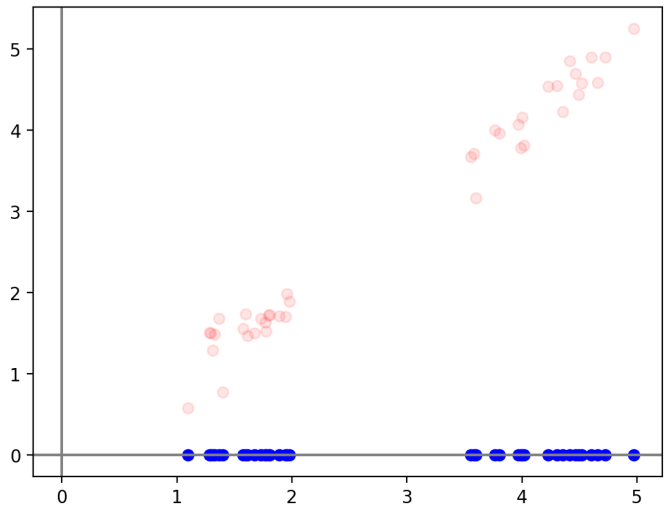

https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SelectKBest.html

Selección de Features: Variance Threshold

Definición

Elimina features con varianza menor a un umbral predefinido.

$$\text{Var}(X) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2$$

Feature	Varianza
X1	0.05
X2	0.15
X3	0.01

VarianceThreshold en scikit-learn

Selección de Features: Variance Threshold

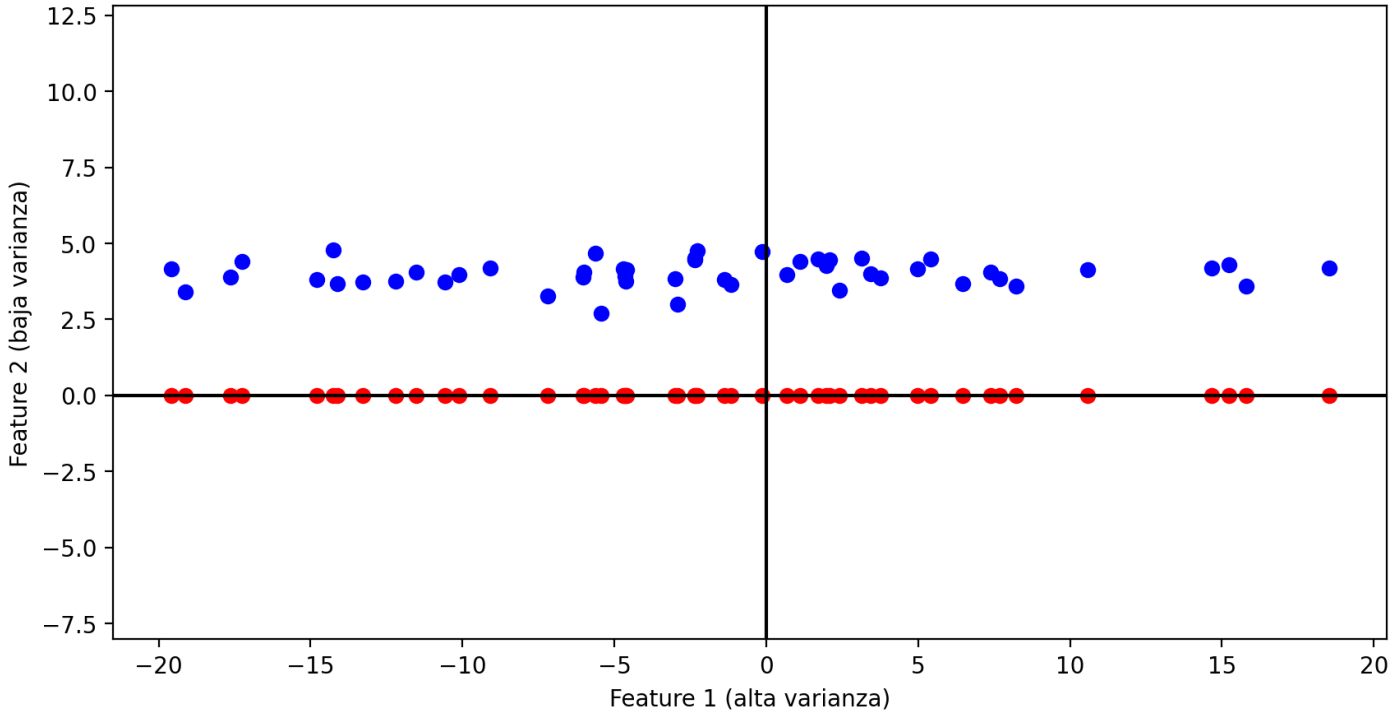

OneHotEncoding

Definición

Convierte variables categorías en vectores binarios. Genera nuevas variables categóricas que sólo pueden tomar valores 0 o 1.

Modelo	Color	Precio
Sedán	Rojo	$25K
SUV	Azul	$32K
Hatchback	Verde	$18K
Sedán	Verde	$22K

Modelo	R	A	V	Precio
Sedán	1	0	0	$25K
SUV	0	1	0	$32K
Hatchback	0	0	1	$18K
Sedán	0	0	1	$22K

OneHotEncoder en scikit-learn

Binning

Definición

Discretiza variables continuas en intervalos.

Edad
12
25
45
18
60
8

[0-20)	[20-40)	[40-60]
1	0	0
0	1	0
0	0	1
1	0	0
0	0	1
1	0	0

Es útil para reducir el ruido, manejar outliers. En algoritmos sensibles a relaciones continuas puede introducir problemas en el rendimiento.

KBinsDiscretizer en scikit-learn

Métodos Clave en Preprocesamiento

`fit()`

- **Aprende** parámetros del transformador
- Ejemplo: Calcula media/desviación para StandardScaler
- Nunca modifica los datos

Métodos Clave en Preprocesamiento

`transform()`

- **Aplica** la transformación usando parámetros aprendidos
- Requiere ejecutar `fit()` primero
- Ejemplo: Estandariza datos con μ y σ calculados

Métodos Clave en Preprocesamiento

`fit_transform()`

- **Aprende y aplica** en un solo paso
- Útil para datos de entrenamiento
- Evita data leakage (contaminación)

`fit` = aprender, `transform` = aplicar, `fit_transform` = aprender + aplicar

Workflow del Machine Learning: Algoritmos

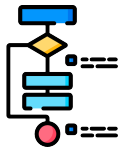

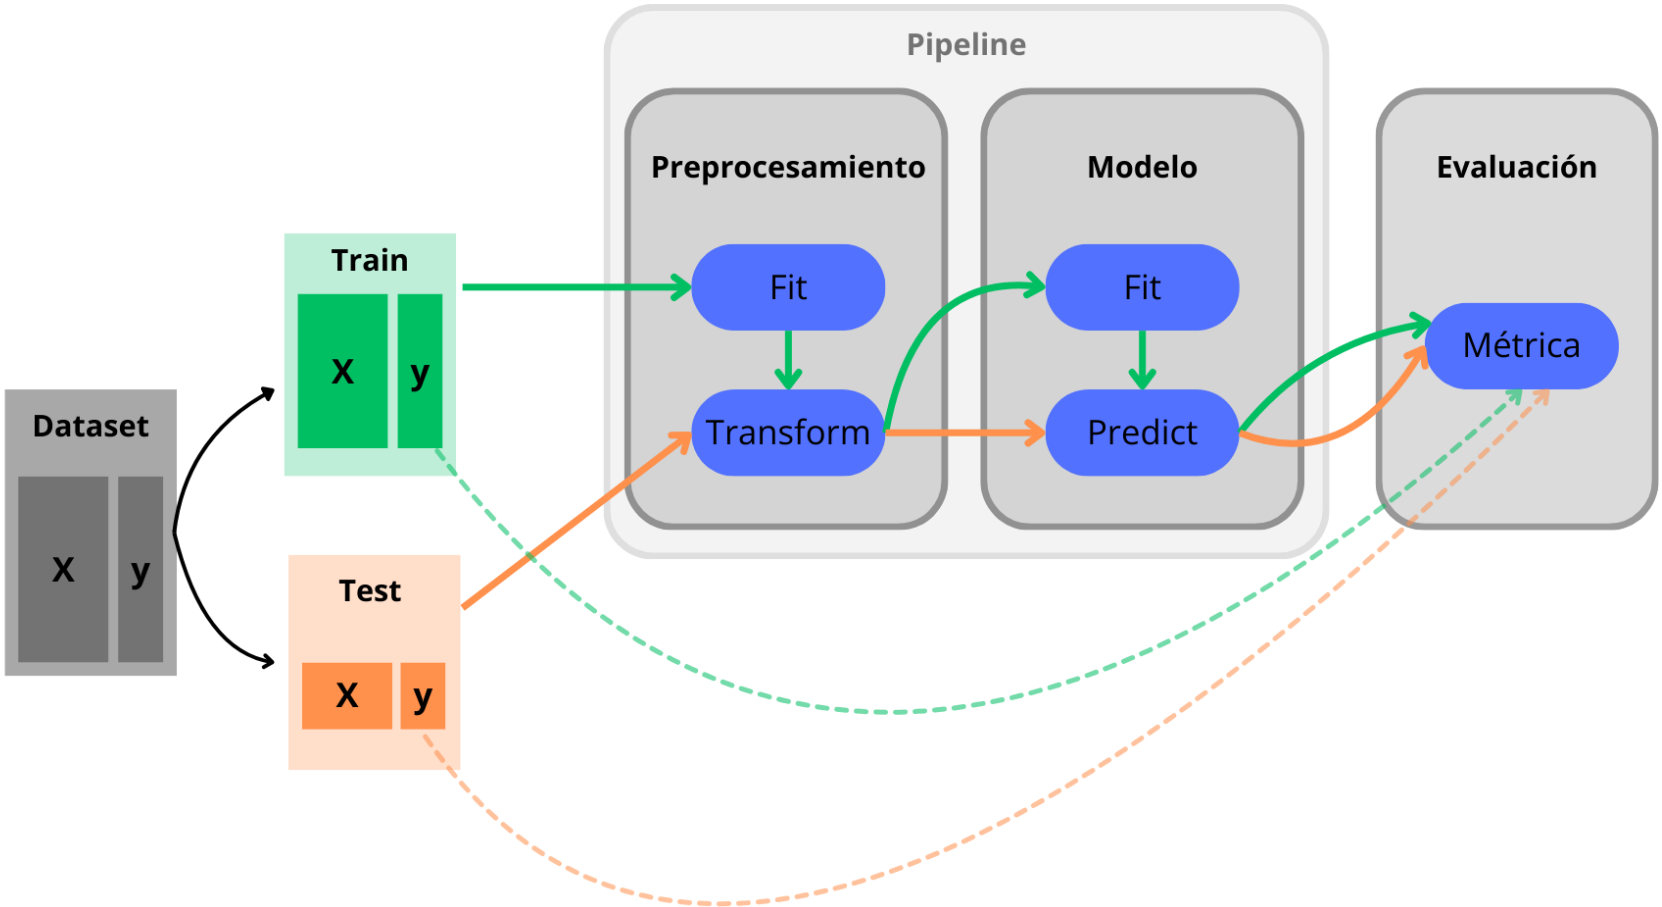

Algoritmos

Un algoritmo de Machine Learning es la técnica que permite a una computadora aprender a partir de datos y tomar decisiones o hacer predicciones basadas en esa información.

Algoritmos

Un algoritmo de Machine Learning es la técnica que permite a una computadora aprender a partir de datos y tomar decisiones o hacer predicciones basadas en esa información.

Existen varios tipos de algoritmos de Machine learning, dependiendo del tipo de tarea que buscar modelar:

- Aprendizaje supervisado.
- Aprendizaje no supervisado.
- Aprendizaje por refuerzo.

Algoritmos


100+ MACHINE LEARNING ALGORITHMS
By @TheInsaneApp
CLUSTERING
- k Means
- k Medians
- BIRCH
- Fuzzy C-Means
- Fuzzy K-Modes
- Mini Batch K-Means
- DBSCAN
- Fuzzy clustering
- Mean-shift
- Optics algorithm
- Expectation Maximization
- Hierarchical Clustering
- Minimum spanning tree
DIMENSIONALITY REDUCTION
- PCA Algorithm
- PCR Algorithm
- PLSR Algorithm
- Sammon Mapping
- MDS Algorithm
- Projection Pursuit
- LDA Algorithm
- ICA Algorithm
- NMF Algorithm
- RDA Algorithm
- MDA Algorithm
- PLSDA Algorithm
- QDA Algorithm
- CCA Algorithm
- Diffusion Map
REGRESSION
- Ordinary Least Squares Regression
- Linear Regression
- Logistic Regression
- Stepwise Regression
- MARS Algorithm
- Locally Estimated Scatterplot Smoothing
DECISION TREE
- Conditional Decision Trees
- Decision Stump
- C4.5 and C5.0
- CHAID
- CART
- ID3
- M5
BAYESIAN
- AODE
- Naive Bayes
- Gaussian Naive Bayes
- Multinomial Naive Bayes
- Bayesian Belief Network
- Bayesian Network
REINFORCEMENT LEARNING
- Q Learning
- SARSA Algorithm
- Deep Q-network
- Learning Automata
- DDPG Algorithm
- NAF Algorithm
- A3C Algorithm
- TRPO Algorithm
- PPO Algorithm
- Constructing Skill Trees
REGULARIZATION
- Ridge Regression
- Elastic Net
- LASSO
- LARS
EMSEMBLE
- GBDT
- GBRT
- Boosting
- Bagging
- AdaBoost
- Random Forest
- Blending Algorithm
- Stacked Generalization
- Gradient Boosting Machines
ANNs
- Perceptron
- MLP Algorithm
- Back-Propagation
- Stochastic Gradient Descent
- Hopfield Network
- RBFN Algorithm
OTHER ML ALGORITHMS (Part 1)
- ALOPEX
- CN2 algorithm
- FastICA
- Feature selection Algorithms
- Linde Buzo Gray Algorithm
- Forward Backward algorithm
- Algorithm Accuracy Evaluation
- Performance Measures
- Optimization Algorithm
- Dynamic Time Warping
- Local Outlier Factor
- Logic Learning Machine
- Markov Chain Monte Carlo
- T Distributed Stochastic neighbor Embedding
- Wake Sleep Algorithm
- Prefrontal Cortex Basal Ganglia Working Memory
RULE SYSTEM
- Cubist
- OneR
- ZeroR
- Ripper
OTHER ML ALGORITHMS (Part 2)
- LogitBoost
- Sparse PCA
- Structured kNN
- WMA Algorithm
- GeneRec
- Leabra
- RProp
DEEP LEARNING
- CNN
- RNNs
- LSTMs
- Stacked Auto Encoders
- Deep Boltzmann Machine
- Deep Belief Networks
INSTANCE BASED
- Learning Vector Quantization
- K Nearest Neighbor
- Self-Organizing Map
- Locally Weighted Learning
- Support Vector Machines
ARL
- Apriori Algorithm
- Eclat Algorithm
- FP Growth Algorithm

Cross Validation

Validación Cruzada

La validación cruzada es una técnica de validación de modelos para evaluar cómo se generalizarán los resultados de un análisis estadístico a un conjunto de datos independiente. La validación cruzada es un método de remuestreo que utiliza diferentes partes de los datos para probar y entrenar un modelo en diferentes iteraciones.

Es necesario tener una validación de la estabilidad de cualquier modelo de Machine Learning. Es decir, ¿qué tan bien podemos esperar que sea su rendimiento en datos que no ha visto?

Tecnicas de validación

- **Validación**: Evaluación del desempeño del modelo en los datos de entrenamiento.

Tecnicas de validación

- **Validación**: Evaluación del desempeño del modelo en los datos de entrenamiento.
- **Conjunto de prueba**: Reservar una parte del conjunto de datos para ser usada como conjunto de prueba.

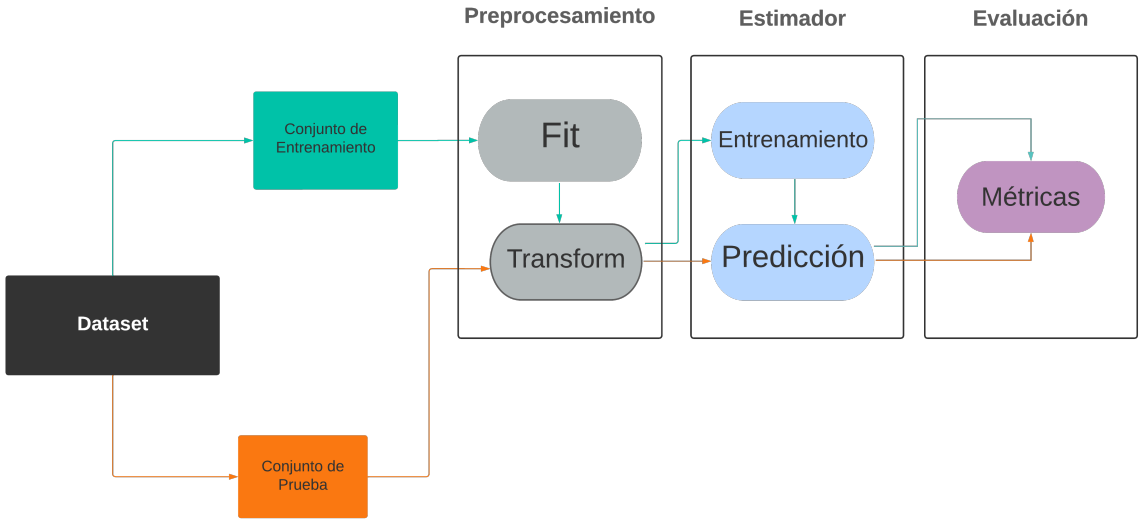

Tecnicas de validación

- **K-Fold Cross Validation**: Los datos se dividen en k subconjuntos, una de las partes se usa como conjunto de prueba y las demás como entrenamiento. Se repite este método k veces, de forma que cada vez, uno de los k subconjuntos se utiliza como conjunto de prueba y los otros $k-1$ subconjuntos, como conjunto de entrenamiento. La estimación del error se promedia sobre las k pruebas para obtener la eficacia total de nuestro modelo.

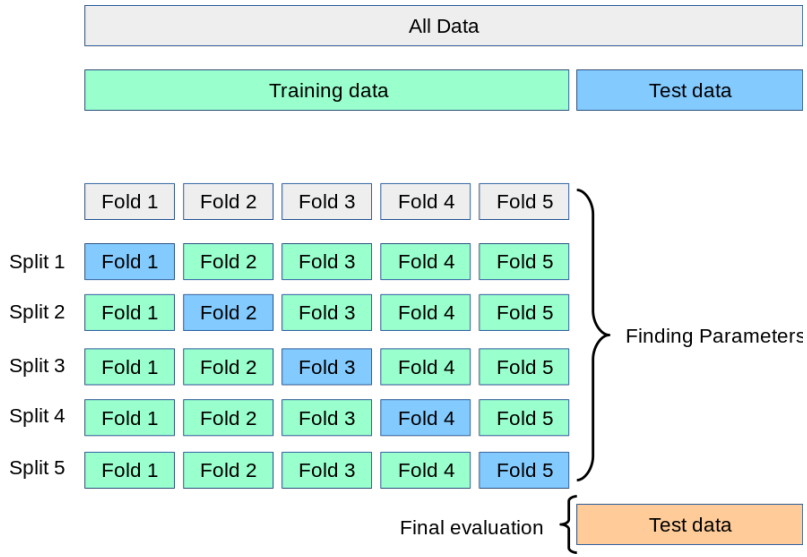

Tecnicas de validación

- **Stratified K-Fold Cross Validation**: Variación de la validación cruzada K-fold normal, en lugar de que las divisiones sean completamente aleatorias, la proporción entre las clases objetivo es la misma en cada uno de los k subconjuntos que en el conjunto de datos completo.

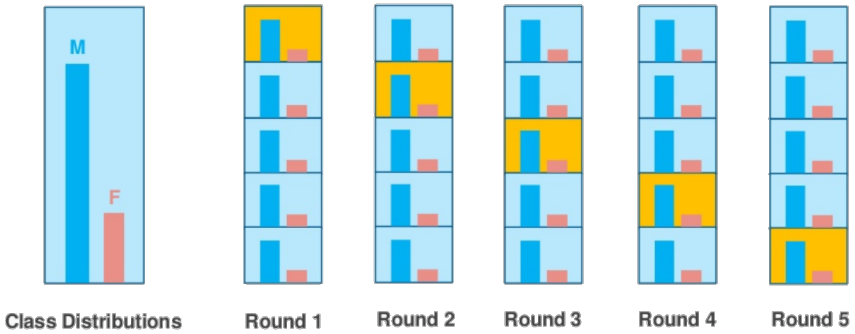

Workflow del Machine Learning: Métricas de rendimiento

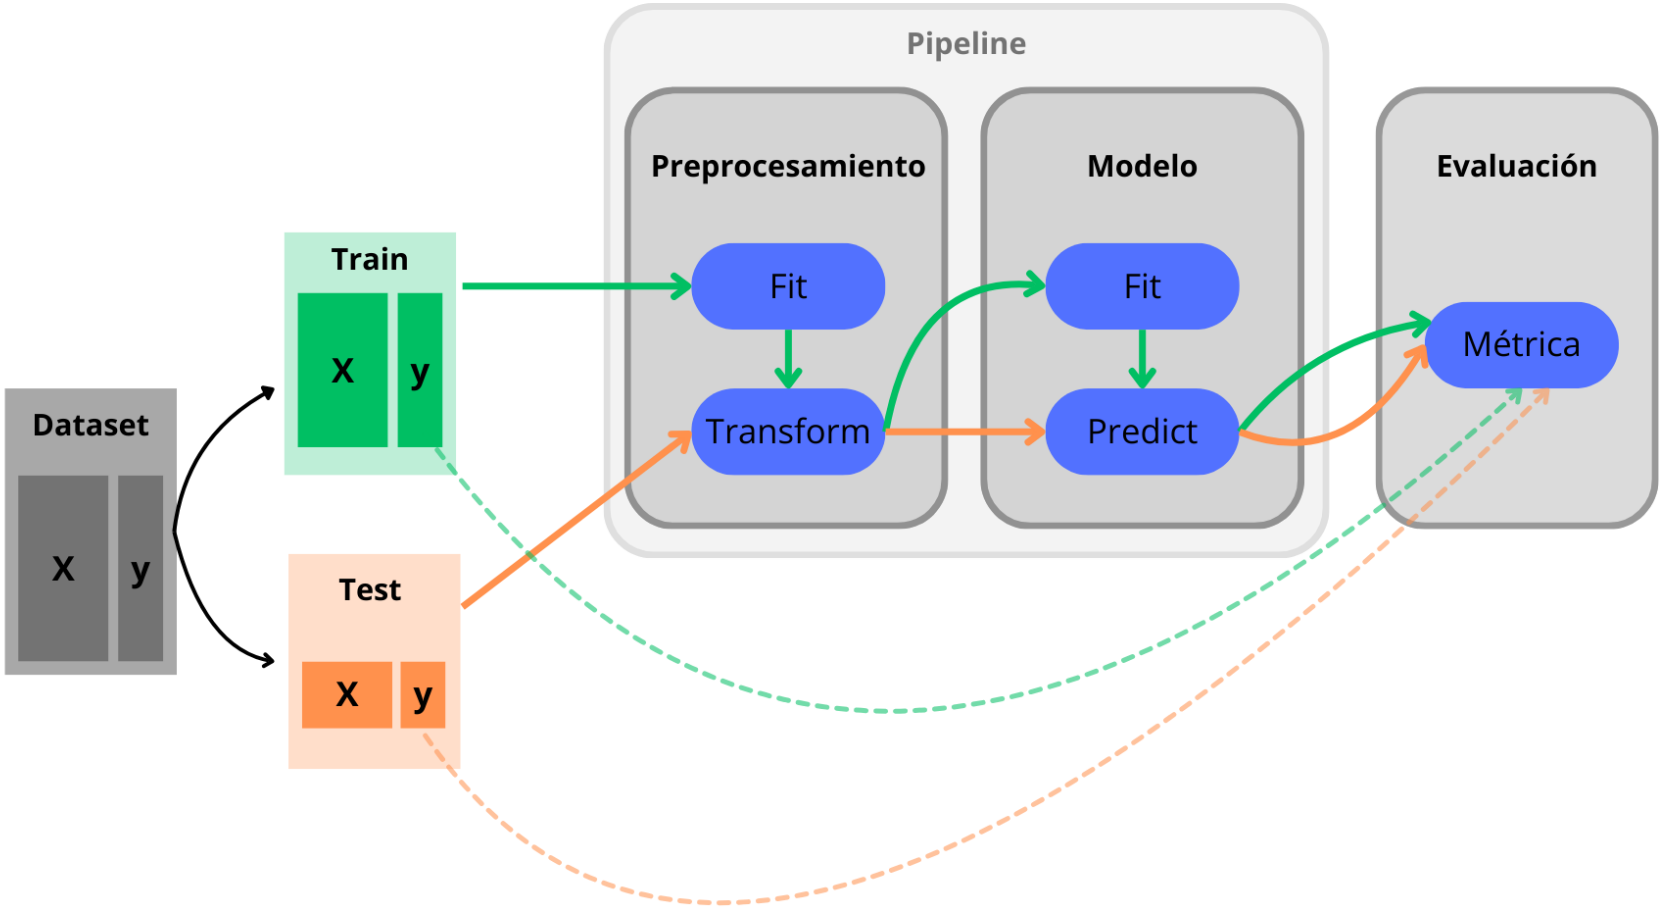

Métricas de desempeño

Las métricas de desempeño dan cuenta del desempeño del modelo entrenado. Estas funciones varían de acuerdo al tipo de tarea, suelen ser funciones *fácilmente* interpretables (porcentajes, conteos, diferencias, etc.).

- Regresión: MSE, MAE.
- Clasificación: Accuracy, precision, recall, F1-score, ROC-AUC.
- Clustering: AMI, MI, silhoutte score.
- Tareas de NLP: Preplexity, entropy, coherence.
- ...

Métricas de desempeño: Ejemplo de clasificación

Hello Friends! We hope you had a pleasant week. Last weeks trivia questions was: What do these 3 films have in common: One Crazy Summer, Whispers in the Dark, Moby Dick? Answer: Nantucket Island	?
IMPORTANT INFORMATION: The new domain names are finally available to the general public at discount prices. Now you can register one of the exciting new .BIZ or .INFO domain names, as well as the original .COM and .NET names for just $14.95. These brand new domain extensions were recently approved by ICANN and have the same rights as the original .COM and .NET domain names. The biggest benefit is of-course that the .BIZ and .INFO domain names are currently more available. i.e. it will be much easier to register an attractive and easy-to-remember domain name for the same price. Visit: http://www.affordable-domains.com today for more info.	?
If you have an internal zip drive (not sure about external) and you bios supports using a zip as floppy drive, you could use a bootable zip disk with all the relevant dos utils.	?

Métricas de desempeño: Ejemplo de clasificación

Hello Friends! We hope you had a pleasant week. Last weeks trivia questions was: What do these 3 films have in common: One Crazy Summer, Whispers in the Dark, Moby Dick? Answer: Nantucket Island	No Spam
IMPORTANT INFORMATION: The new domain names are finally available to the general public at discount prices. Now you can register one of the exciting new .BIZ or .INFO domain names, as well as the original .COM and .NET names for just $14.95. These brand new domain extensions were recently approved by ICANN and have the same rights as the original .COM and .NET domain names. The biggest benefit is of-course that the .BIZ and .INFO domain names are currently more available. i.e. it will be much easier to register an attractive and easy-to-remember domain name for the same price. Visit: http://www.affordable-domains.com today for more info.	Spam
If you have an internal zip drive (not sure about external) and you bios supports using a zip as floppy drive, you could use a bootable zip disk with all the relevant dos utils.	No Spam

Accuracy (Clasificación)

Accuracy

$$\text{Accuracy} = \frac{\text{Aciertos}}{\text{Total}}$$

- Mide la proporción de predicciones correctas
- Ideal para clases balanceadas
- Ejemplo:
  - Reales: [0, 1, 0, 1]
  - Predicciones: [0, 1, 1, 1]
  - Accuracy: $\frac{3}{4} = 0.75$ (75%)

Métricas de desempeño: Ejemplo de regresión

Altura	Peso
169.948447	**?**
173.865754	**?**
174.661475	**?**
170.597762	**?**

Métricas de desempeño: Ejemplo de regresión

Altura	Peso
169.948447	82.552060
173.865754	75.674023
174.661475	84.338528
170.597762	87.721204

MAE (Regresión)

MAE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- Error promedio absoluto
- Menos sensible a outliers que MSE
- Ejemplo:
  - Reales: [170, 180, 175] cm
  - Predicciones: [172, 177, 173] cm
  - MAE: $\frac{2+3+2}{3} \approx 2.33$ cm

Funciones de costo

Una función de pérdida, o función de costo, es una función que asigna un evento o los valores de una o más variables a un número real que representa intuitivamente algún *costo* asociado al evento. Un problema de optimización trata de minimizar una función de pérdida.

Un algoritmo de Machine Learning busca minimizar o maximizar esta función cambiando sus parámetros internos. Frecuentemente se usa el descenso de gradiente para este fin, por lo tanto, tipicamente se requiere de una función de costo diferenciable o convexa.

- Regresión: MSE, RMSE, MAE.
- Clasificación: 0-1, binaria asímetrica, entropia cruzada, Hinge loss.

Diferencia entre función de costo y métrica de desempeño

Típicamente son funciones diferentes, bajo ciertas condiciones se puede usar la misma.

- Usando la función de costo como métrica de desempeño: puede ser confusa de interpretar.
- Usando la métrica de desempeño como función de costo: puede no ser posible si no es diferenciable o convexa.

Resumiendo

Un problema de Machine Learning consiste en los siguientes pasos:

- **Recopilación de datos:** Los datos deben ser suficientes y representativos del problema que se busca resolver.
- **Preprocesamiento:** Limpiar los datos para eliminar ruido, valores faltantes, valores atípicos, y los prepara para su uso en el modelo.
- **Selección del algoritmo**.
- **Entrenamiento del modelo:** Utiliza el conjunto de datos de entrenamiento para entrenar el modelo elegido. La mejora se rige usando la función de costo.
- **Evaluación del modelo:** Evalúa el modelo utilizando el conjunto de datos de prueba. Esto se hace con la métrica de rendimiento.
- **Implementación, Monitoreo y Mantenimiento.**

Table of Contents

¿Por qué Python?

Ventajas

- Rápido de aprender.
- El código es claro y fácil de leer.
- Desarrollo rápido de modelos.
- Lenguaje orientado a objetos.
- Muchas librerias: Numpy, Pandas, Scipy, Matplotlib.

Machine Learning

Deep Learning

Ciencia de Datos

Ciencia de datos

La ciencia de datos es una disciplina que analiza grandes cantidades de datos para extraer información y patrones que sea útiles en la creación de estrategias que permitan aumentar la eficiencia, reconocer nuevas oportunidades de mercado y aumentar la ventaja competitiva de una organización.

La ciencia de datos emplea las disciplinas de las matemáticas, estadística y las ciencias de la computación. Además, incorpora técnicas del Machine Learning, la mineria de datos y la visualización, entre otras.

El proceso de la ciencia de datos

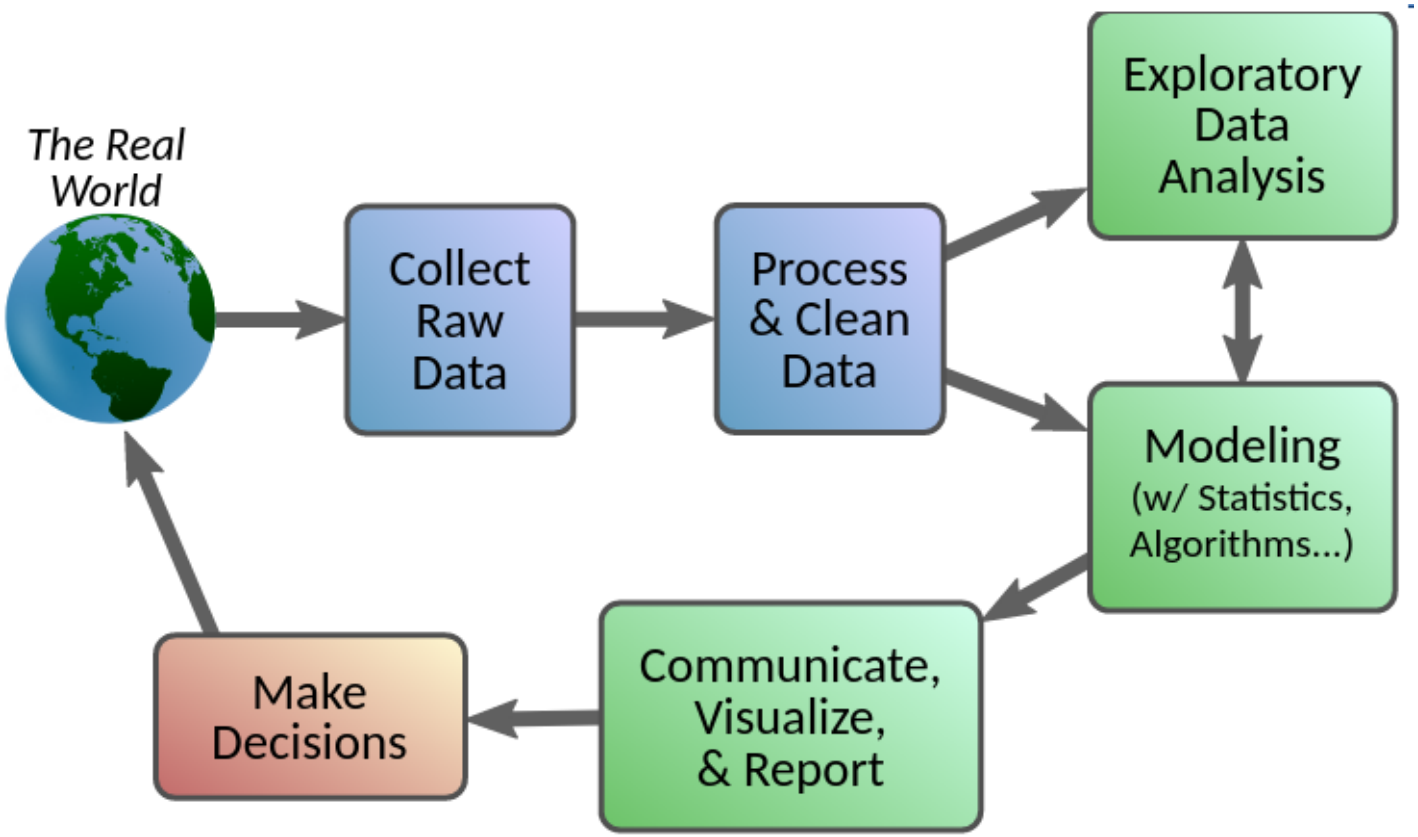

https://snakebear.science/01-Introduction/WhatIsDS.html

¡Vamos a comenzar!

Welcome to the world of Machine Learning